

Nengo 프레임워크에서 SNN(Spiking Neural Networks) 응용의 성능 분석

Performance Analysis of Spiking Neural Networks (SNNs) based Applications in Nengo Framework

저자 (Authors)	김서연, 정재혁, 김찬수, 김경수, 최승호, 윤영선, 정진만 Seoyeon Kim, Jaehyeok Jeong, Chansoo Kim, Kyeongsoo Kim, Seungho Choi, Young-Sun Yun, Jinman Jung
출처 (Source)	한국정보과학회 학술발표논문집 , 2019.12, 836-838 (3 pages)
발행처 (Publisher)	한국정보과학회 The Korean Institute of Information Scientists and Engineers
URL	http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE09301747
APA Style	김서연, 정재혁, 김찬수, 김경수, 최승호, 윤영선, 정진만 (2019). Nengo 프레임워크에서 SNN(Spiking Neural Networks) 응용의 성능 분석. 한국정보과학회 학술발표논문집, 836-838.
이용정보 (Accessed)	한성대학교 220.66.103.*** 2020/06/13 01:47 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

Nengo 프레임워크에서 SNN(Spiking Neural Networks)

응용의 성능 분석

김서연[○] 정재혁 김찬수 김경수 최승호 윤영선 정진만

한남대학교 정보통신공학과

sykim.hn@gmail.com, jhjeong.esw@gmail.com, racio54112@gmail.com, kskim.hci@gmail.com, tmdgh91105@gmail.com, ysyun@hnu.kr, jmjung@hnu.kr

Performance Analysis of Spiking Neural Networks (SNNs) based Applications in Nengo Framework

Seoyeon Kim[○] Jaehyeok Jeong Chansoo Kim Kyeongsoo Kim Seungho Choi

Young-Sun Yun Jinman Jung

Department of Information and Communication Engineering, Hannam University

요 약

최근 SNN(Spiking Neural Network)모델은 실제 신경세포의 스파이크(spike) 전달과 처리과정을 모형화하여 에너지 효율성 측면 등 기존 딥러닝 모델의 문제를 해결할 수 있는 방법으로 3세대 인공지능모델로 불린다. 주로 뇌과학 분야에서 생물학적 신경시스템의 모형화 및 특성 분석을 위한 도구로서 SNN 시뮬레이션을 위한 소프트웨어들이 활용되고 있다. 대부분 인간의 두뇌를 분석하기 위해 대규모 신경세포로 구성된 신경시스템의 동적특성을 반영한 수학적 모델과 광범위한 인자들로 구성된 시뮬레이션을 목적으로 하고 있어 기계학습분야에 아직 많이 활용되지 않고 있다. 최근 Nengo와 같은 SNN 시뮬레이션 프레임워크를 활용하여 SNN 모델을 지도, 비지도 및 강화학습 분야의 응용에 적용하기 위한 연구들이 시도되고 있다. 본 논문에서는 Nengo 프레임워크에서 SNN 모델 기반 응용을 구현하여 성능을 분석한다. 지도학습의 대표적인 예인 선형회귀(Linear Regression), 로지스틱회귀(Logistic Regression), 다중분류(Multi-class Classification)의 사례를 통해 성능 평가를 한다.

1. 서 론

SNN(Spiking Neural Network)모델 [1]은 다양한 뉴로 모픽 아키텍처 하드웨어의 지원으로 낮은 전력소비와 높은 컴퓨팅을 특징으로 하고 있어 기계학습 분야에서 딥러닝 모델을 대체 할 수 있는 방법으로 기대되고 있다. 대규모의 뉴런과 시냅스로 구성된 신경시스템을 설계하고 시뮬레이션을 하기 위한 소프트웨어 프레임워크로서 PACMAN[2], Neural ENGineering Objects (Nengo)[3], Pynn[4] 등이 활용되고 있다. 기존 SNN 시뮬레이션 프레임워크는 뉴런과 신경시스템의 세부적인 상호작용과 처리에 대한 모형화에 집중되어 정보처리 관점에서 기계학습 알고리즘에 적용하고 이를 응용에 활용하는데 적합하지 않다.

SNN 모델에서 생물학적인 뉴런들은 자극에 따라 세포막의 전위차가 변화하고 분극, 탈분극, 재분극 과정이 발생하는데 이를 LIF(Leaky Integrate and Fire), Izhikevich, Hodgkin-Huxley 등과 같은 뉴런모델로 모형화한다. 이러한 뉴런 모델들은 대부분 캐패시터와 저항을 가진 병렬 RC 회로와 유사하여 시간에 따른 미분방정식의 형태로 동적 특성을 모사한다. 뉴런들은 입력된

자극에 따라 세포막 전위가 변화하고 임계 전압에 이르렀을 때 축삭돌기를 통해 시냅스를 거쳐 다른 뉴런의 수상돌기로 스파이크를 전달한다. 생물학적인 특성이 세포마다 다르기 때문에 각 모델에 따라 자극에 의한 단위시간당 스파이크의 발생 비율, 전위 변화량, 노이즈 모델 등의 많은 인자가 존재한다.

이러한 많은 인자들로 인해 SNN 모델을 공학 분야에서 기계학습 응용으로 적용할 때 어려움이 있다. 또한 임계 전압에 이르렀을 때 발생하는 스파이크 모델은 미분이 어렵기 때문에 경사하강법(gradient descent)을 근간으로 하는 대부분의 딥러닝 알고리즘에 적용하기 어렵다. 최근 Nengo에서는 스파이크들의 비율(Rate) 변환을 통해 학습 알고리즘에 적용하여 기계학습에 적용할 수 있는 프레임워크를 제공하여 기계학습으로서 SNN 모델의 활용성을 더욱 높여주고 있다.

본 논문에서는 Nengo 프레임워크에서 SNN 모델 기반 응용을 구현하여 성능을 분석한다. 지도학습의 대표적인 예인 선형회귀(Linear Regression), 로지스틱회귀(Logistic Regression), 다중분류(Multi-class Classification)를 sklearn Iris, Low birth weight, MNIST 데이터셋을 각각 사용하여 성능 평가를 한다. 특히 SNN 모델에서 뉴런의 인자가 성능에 주는 영향을 함께 분석한다.

2. SNN 기반 회귀 및 분류의 성능 분석

2.1 실험 모델

SNN 모델의 응용에서 적용 가능성을 평가하기 위해 Nengo 프레임워크 환경에서 지도학습의 대표적인 문제인 선형회귀(Linear Regression), 로지스틱회귀(Logistic Regression), 다중분류(Multi-class Classification)를 구현하였다. 첫 번째 실험은 그림 1과 같이 가장 단순한 형태의 SNN 모델이며 하나의 뉴런으로 구성된 선형회귀로 sklearn의 Iris 데이터셋을 사용하였다. Iris 데이터셋은 3가지 종(setosa, versicolor, virginica)의 꽃받침 길이, 꽃받침 너비, 꽃잎 길이, 꽃잎 너비 정보를 종마다 50개씩 정리한 데이터이다. 본 실험에서는 setosa 종에 대한 꽃받침 너비와 꽃잎 너비를 학습시키고 꽃받침 너비를 입력하였을 때 꽃잎 너비를 예측하는 회귀 문제의 예이다. 입력은 50개의 데이터 중 43개의 데이터로 학습시키고 7개의 데이터로 테스트하여 MSPE(Mean Square Percentage Error)를 계산하였다. SNN 모델은 하나의 양상블과 하나의 뉴런으로 네트워크를 구성하였다.




그림 1 SNN기반 선형 회귀(Iris)

두 번째 실험은 그림 2와 같이 역시 하나의 뉴런으로 네트워크가 구성되나 다중 입력을 받아 이진 선택을 하는 로지스틱 회귀이다. Low birth weight 데이터를 사용하였고 산모의 7가지 특성(나이, 산모의 체중, 인종, 흡연 여부, 조기분만, 고혈압, 자궁과민)을 바탕으로 태아의 저체중(2500g) 유무를 정리한 데이터이다. 총 189개의 데이터 중 130개의 데이터가 정상체중, 59개의 데이터가 저체중이다. 셔플링후에 161개의 데이터를 랜덤 선택하여 학습시키고 나머지로 테스트하여 저체중 유무 예측의 정확도를 측정하였다. SNN 모델은 하나의 양상블과 하나의 뉴런으로 네트워크를 구성하였다.




그림 2 SNN기반 로지스틱 회귀 (Low birth weight)

세 번째 실험은 그림 3과 같이 SNN 모델로 convolution 계층과 pooling 계층을 적용하여 MNIST 데이터셋으로 다중 분류하는 실험이다. 5개의 계층을 적용하였으며 NengoDL 프레임워크에서 제공하는 API를 사용하였다. 숫자 필기체 이미지를 입력받아 마지막 FC(Fully Connected) 계층에서 10개 노드의 출력을 통해 숫자를 예측하기 위해 50000개를 학습하였고, 200개의 데이터로 테스트하였다. 실험에서 뉴런의 모델은 모두 LIF 모델을 사용하였고 max_rate는 50, 100, 150, 200, 250, tau_rc는 0.02, 0.07, 0.12, 0.17, 0.22. synapse=0.001, 0.01, 0.1, 1로서 다양한 인자에 따른 MSPE와 정확도를 분석하였다.

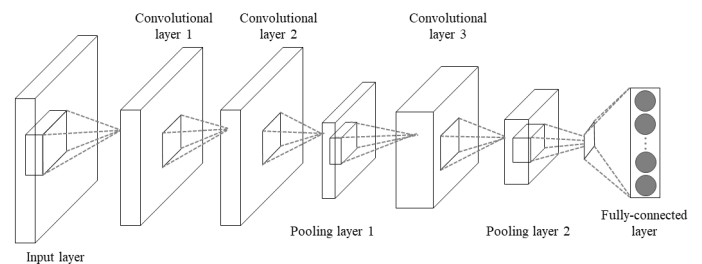




그림 3 SNN기반 다중 분류 (MNIST)

2.2 실험 결과


그림 4 (a)~(c)는 첫번째 실험인 선형회귀 실험에 대한 결과를 보여준다. 꽃받침 너비를 입력하였을 때 꽃잎 너비를 예측하도록 구성된 실험에서 정답에 대한 상대적인 오차 비율을 확인하기 위해 MSPE를 사용하였다. amplitude는 1로 고정하였고, tau_rc=0.02, max_rate, , synapse 단일 뉴런으로 구성된 실험에서 synapse 만이 성능에 영향을 미쳤다. nengo에서 synapse 인자는 뉴런 출력값의 Lowpass 필터를 의미하는 값으로 출력값에 영향을 미친다. 그림 4 (d)~(f)는 두번째 실험 로지스틱회귀의 실험에 대한 정확도(%)를 보인다. 7가지 특성을 입력으로 하여 저체중 유무를 예측하는 문제로서 28개 테스트셋에 대한 결과이다. 로지스틱회귀에서 synapse 영향은 선형회귀 실험에서 MSPE에 미치는 영향보다 미미하였다. 모든 뉴런 인자들에 의해 정확도 변화는 크게 없는 것으로 파악된다. 단일 뉴런 실험인 선형회귀 실험에서 뉴런 인자 중 synapse에 의해 결과가 달라질 수 있음




(a) 선형회귀에서 max_rate 효과




(b) 선형회귀에서 tau_rc의 효과




(c) 선형회귀에서 synapse효과




(d) 로지스틱회귀에서 max_rate 효과




(e) 로지스틱회귀에서 tau_rc 효과




(f) 로지스틱회귀에서 synapse효과



(g) 다중분류에서 max_rate 효과



(h) 다중분류에서 tau_rc 효과



(i) 다중분류에서 synapse효과

그림 4 실험 결과

을 확인하였다. 그림 4 (g)~(i)는 세 번째 실험인 MNIST 다중분류 실험에 대한 정확도를 나타낸다. nengo에서는 텐서플로우 라이브러리와 결합하여 시뮬레이션이 가능하도록 지원한다. amplitude는 0.01로 고정된 MNIST 실험에서는 max_rate은 100이하인 경우 정확도가 좋지 않은데 안정적인 결과를 위해서는 amplitude와 max_rate의 크기가 함께 고려되어야 함을 의미한다. 다중 계층을 통한 여러 실험에서 다양한 인자가 정확도 성능에 영향을 줄 수 있음을 의미한다.

3. 결론

본 논문에서는 Nengo 프레임워크에서 SNN 모델 기반 회귀 및 분류 문제를 구현하여 성능을 분석하였다. SNN 모델을 기계학습에 적용하기 위해서는 기존 2세대 뉴런 모델에 비해 더 많은 뉴런 인자에 대한 이해를 필요로 한다. LIF 모델을 적용하여 SNN 기반의 선형회귀, 로지스틱회귀, 다중분류를 실험한 결과 다양한 뉴런 인자에 의해 성능이 달라질 수 있음을 확인하였다.

사사

이 논문은 2019년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임 (No.2019-0-00708, 뉴로모픽 아키텍처 기반 자율형 IoT 응용 통합개발환경).

참고문헌

- [1] Maass W. Networks of Spiking neurons: the third generation of neural network models [J]. Neural networks. 1997, (10): 1659~1671
- [2] Galluppi, F., Davies, S., Rast, A., Sharp, T., Plana, L. A., Furber, S. A, "Hierarchical Configuration System for a Massively Parallel Neural Hardware Platform", In Proceedings of the 9th conference on Computing Frontiers, ACM Press: New York, p 183, 2012.
- [3] Davison, A. P., "PyNN: A Common Interface for Neuronal Network Simulators.", Neuroinform. 2008, 2.
- [4] TC Stewart, B Tripp, and C Eliasmith. "Python scripting in the Nengo simulator", Frontiers in Neuroinformatics, 3(0), 2009