

뉴로모픽 심층 스파이킹 신경망

DOI: 10.3938/PhiT.28.014

최 영 석

Neuromorphic Learning: Deep Spiking Neural Network

Young-Seok CHOI

Recently, deep learning has revolutionized the field of machine learning, for computer vision in particular. Nevertheless, biological neurons use discrete spikes to compute and transmit information, and the spike times, in addition to the spike rates, matter. Spiking neural networks (SNNs) are, thus, biologically realistic and are arguably the only viable option if one wants to understand how the brain computes at the neuronal description level. Combined with bio-plausible local learning rules, this makes building low-power, neuromorphic hardware for SNNs easier. However, training deep SNNs remains a challenge. Here, we present supervised and unsupervised methods to train deep SNNs and compare them in terms of architecture and performance.

들어가는 글

인공 신경망(artificial neural network)은 연속적인 활성화 값과 가중 입력 집합을 가진 이상적인 계산 단위를 사용하여 구축된다. 이 단위들은 생물학적 유사성에 기인하여 '뉴런'이라고 불린다. 이 뉴런들은 미분 가능하며 비선형 활성화 함수를 사용한다. 비선형 활성화 함수는 둘 이상의 계층(layer)을 쌓는 것을 의미있게 만들며 활성화 함수의 미분 가능한 특성은 경사도(gradient) 기반 최적화 방법을 사용하여 훈련을 수행할수 있게 한다.[1] 최근 대형 데이터 셋의 가용성, 범용 GPU 컴

저자약력

최영석 교수는 포항공과대학교 전자컴퓨터공학부에서 2007년 박시학위를 취득 후, 미국 존스홉킨스 의대 의공학과 박사후연구원, 한국전자통신연구원 선임 연구원, 강릉원주대학교 전자공학과 조교수를 거쳐, 2016년부터 광운대학교 전자통신공학과 부교수로 재직 중이며, 뇌공학 및 뉴로모픽 연구를 진행하고 있다.(yschoi@kw.ac.kr)

퓨팅 형태의 컴퓨팅 능력, 고급 정규화 방법의 발전으로 인해 수십 개의 레이어로 구성된 인공 신경망은 숨겨진 데이터를 일반화하는 역할을 성공적으로 수행하게 되었으며 성능측면에 서 주목할 만한 성능 개선이 이루어졌다.^[2]

심층 신경망(deep neural network)은 생물학적 뇌기능을 모사하여 개발되었지만, 뇌에 비해 구조, 신경 계산, 학습 규칙에는 근본적인 차이가 있다. 가장 중요한 차이점은 뉴런 간에 정보가 전파되는 방식이다. 실제 뇌의 뉴런들 사이의 정보 전달은 스파이크 열(spike train)이라고도 알려진 활동 전위(action potential)를 다음 뉴런으로 전달함으로써 이루어진다. 각 스파이크는 시간적으로 희소(sparse)하기 때문에 각 스파이크는 높은 정보 내용을 가지고 있으며, 첫 번째 근사치까지는 균일한진폭(약 1 msec의 스파이크 폭의 100 mV 진폭)을 가진다. 이러한 과학적 관찰은 스파이킹 신경망(spiking neural network)의 개발로 이어졌다. 스파이킹 신경망의 정보는 대기 시간을포함한 스파이크 타이밍과 스파이크 속도를 통해 전달된다.[3] 스파이킹 신경망은 실제 생물 물리학적 메커니즘에 대조적으로이상화된 스파이크 생성 메커니즘을 보편적으로 사용한다.

인공 신경망 중 비 스파이킹 심층 신경망 모델은 연속적인 값의 활성화를 사용하여 정보를 전달한다. 이에 비해 스파이킹 심층 신경망은 스파이크 이벤트가 시간적으로 희박하기 때문에에너지 효율 측면에서 기존의 심층 신경망 모델들보다 우수하다. 또한 스파이킹 신경망은 생물학적 신경 시스템에서 발생하는 정보 전달의 시간적 특성에 본질적으로 민감하다는 장점이었다. 모든 스파이크의 정확한 타이밍은 뇌의 여러 부분에 대해 정보표현의 중요한 역할을 담당하며, 신경정보 부호화를 수행하는 것으로 밝혀졌다.[4] 이러한 정확한 시간 패턴은 감각

- [1] Y. LeCun, Y. Bengio and G. Hinton, Nature **521**, 436 (2015).
- [2] I. Goodfellow, Y. Bengio, A. Courville and Y. Bengio, *Deep Learning* (Cambridge, MIT Press, 2016).
- [3] A. L. Hodgkin and A. F. Huxley, The Journal of Physiology 117, 500 (1952).
- [4] W. Bair and C. Koch, Neural Computation 8, 1185 (1996).

정보처리 뇌 기능과 신경 운동 제어 뇌 기능의 중요한 부호화도구이다. ^[5] 또한 최근 스파이킹 신경망은 시각 정보 처리, 음성 인식, 의료 질병 진단 등의 패턴 인식 분야에 응용이 활발히 이루어지고 있다. ^[6] 이에 발맞춰 최근 스파이킹 신경망에서 심층 신경망 및 생물학적 뇌의 다층 구조와 그 유형을 통합한 새로운 세대의 신경망 모델들이 개발되었다.

복잡한 시각적 패턴을 인식하거나 잡음이 많은 환경에서 청각 목표를 식별하는 뇌의 능력은 심층 스파이킹 신경망에 내재된 여 러 처리 단계 및 다중 학습 메커니즘으로 가능하다. 하지만, 기존 의 심층 신경망과 비교하여 심층 스파이킹 신경망의 훈련에 관한 연구는 초기 단계에 머물러 있다. 하지만 심층 스파이킹 신경망의 시간과 공간에서의 정보의 표현방식으로 인해 뇌를 모사한 수리 계산을 수행하고 시공간 패턴에서의 뇌 데이터 및 활동을 이해하 기 위한 심층 스파이킹 신경망이 최적의 기법으로 여겨진다.

공학적 관점에서 심층 스파이킹 신경망은 특수 목적 하드웨어에서의 구현과 관련하여 전통적인 신경망에 비해 장점을 가지고 있다. 현재 기존의 심층 신경망의 효과적인 훈련을 위해서는 고용량의 에너지를 소모하는 그래픽 카드가 필요하다. 스파이킹 신경망은 출력 스파이크 열이 시간상으로 희소하게 만들어지는 특성이 있다. [7] 스파이크 이벤트가 에너지를 소비하고 정보량이 많은 스파이크를 사용하면 에너지 소비가 감소하는 것이 생물학적 신경망의 장점이다. 이와 같은 장점은 하드웨어 구현에서도 유지된다. 따라서 스파이크가 시간적으로 희소한 특성을 기반으로 이벤트 기반 센서에 민감한 저에너지소모 스파이크 하드웨어를 만들 수 있다.

생물학적 뇌를 모사한 스파이킹 신경망은 기존의 스파이크 발화량 기반 부호화 망에 비해 높은 표현 능력을 지난다. 또한 신경 망의 가중치 업데이트에 필요한 정보를 국소적으로 이용할 수 있는 직접 연결된 뉴런 쌍 사이의 스파이크 타이밍에 의존하는 생물학적 학습 패턴을 구현할 수 있다. 이러한 국소적인 학습은 뇌의 많은 부분에서 일어나는 학습기전과 유사하다. 스파이크 열은 디락 델터 함수(Dirac delta function)의 합으로 표현되며 미분이불가능하다. 이러한 특성 때문에 스파이킹 신경망의 학습에 있어 미분 기반의 최적화를 적용하기 어려워 심층 학습의 발전이 늦어졌다. 최근 이를 해결한 심층 스파이킹 신경망 연구가 활발하다.[8]

본 원고에서는 뇌신경을 모사한 뉴로모픽 기술 중 뉴로모픽 알고리즘의 소개를 위해 심층 스파이킹 신경망 알고리즘에 관 해 기술하고자 한다.

생물학적 뉴런 모델링

생물학적 신경 시스템인 뇌는 뉴런으로 구성되어 있고, 각기 다른 뉴런은 시냅스(synapse)를 통해 연결된다. 시냅스는 뉴런

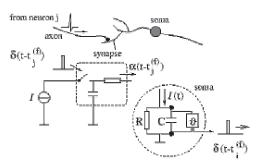


Fig. 1. Schematic diagram of the integrate-and-fire model. [9] The basic circuit is the module inside the dashed circle on the right-hand side. A current I(t) charges the RC circuit. The voltage u(t) across the capacitance (points) is compared to a threshold ϑ . If u(t) = ϑ at time $t_i^{(f)}$ an output pulse $\delta(t-t_i^{(f)})$ is generated. Left part: A presynaptic spike $\delta(t-t_i^{(f)})$ is low-pass filtered at the synapse and generates an input current pulse $\alpha(t-t_i^{(f)})$.

에서 신경 물질을 전달하는 축색돌기(axon)와 전달 물질을 취합하는 수상돌기(dendrite)로 구성된다. 수상돌기에 일정 수준이상의 정보가 전달되면 뉴런에서는 일종의 전기적 신호인 스파이크를 발생시키고, 생성된 신경 신호는 시냅스를 통해 인접한 뉴런으로 전달된다.^[9](그림 1 참조) 스파이크 생성 속도와스파이크 열의 시간적 패턴을 활용하여 외부 자극에 대한 정보를 전달한다. 스파이킹 신경망은 이러한 시냅스를 통해 정보를 전송하는 뇌의 신경정보 처리 기전을 모방한 것이다.

스파이킹 신경망은 뉴런들과 뉴런들을 연결하는 시냅스로 이루어지며 시냅스는 조절 가능한 스칼라의 가중치(weight)로 모델링된다. 활동전위 생성 및 신경망의 동적 기전을 갖는 생물학적 신경망과 비교하면 인공 스파이킹 신경망의 동작 기전은 매우 단순화되었다. 앞서 기술한 생물학적 특성을 따라 Hodgkin-Huxley, [4] Izhikevich, 「10] leaky-integrate-and-fire(LIF) 등의 뉴런 모델들이 제시되었는데, 스파이킹 신경망에서는 LIF 뉴런 모델이 주로 사용된다. u(t)는 막전위로서 이전 뉴런에서 전달되는 활동 전위인 스파이크와 시냅스의 연결강도를 나타내는 가중치와의 곱 정보로부터 전위가 바뀌게 된다. 아웃풋 뉴런에 연결된 각각 다른

- [5] D. A. Butts, C. Weng, J. Jin, C.-I. Yeh, N. A. Lesica, J.-M. Alonso and G. B. Stanley, Nature 449, 92 (2007).
- [6] M.-J. Escobar, G. S. Masson, T. Vieville and P. Kornprobst, International Journal of Computer Vision 82, 284 (2009).
- [7] J. V. Stone, *Principles of neural information theory: Computational neuroscience and metabolic efficiency* (Sebtel Press, 2018).
- [8] J. H. Lee, T. Delbruck and M. Pfeiffer, Frontiers in Neuroscience 10, 508 (2016).
- [9] W. Gerstner and W. M. Kistler, Spiking Neruon Models (Cambridge University Press, 2002).
- [10] E. M. Izhikevich *et al.*, IEEE Transactions on Neural Networks **14**, 1569 (2003).

인풋 뉴런의 스파이크와 가중치 곱의 합인 입력 전류 I(t)는 커 패시터의 전하량을 변화시키게 되고, 막전위가 사전에 정해놓은 문턱 값(Threshold) ϑ 을 넘어섰을 때 새로운 아웃풋 스파이크를 발생(Fire)시키게 된다. 만약 일정시간 동안 유입되는 전류가 없다면 u(t)는 막전위 시상수 $\tau_m = RC$ 에 따라 감소한다.[11]

스파이킹 신경망

인공 신경망의 이전 계층(Layer)에 위치한 모든 뉴런은 다음 계층에 있는 각 뉴런과 모두 연결되며 각각의 연결은 시냅스를 형성한다. 시냅스는 가중치로 나타내지며 실제 학습의 대상이 된다. 인공 신경망에서는 학습(learning)은 스칼라 값의 시냅스 가중치의 조절을 통해 이루어진다. 생물학적으로 시냅스의 연결 강도가 자유자재로 강해지고 약해지는 신경 가소성의 성질은 곧 뇌의 학습에 기반이 되고, 뉴로모픽 공학에선 이러한 생물학 적 양상을 따라 현재 스파이크를 기반으로 한 신경망 학습 알 고리즘 연구가 진행되고 있다. 현재까지 여러 종류의 학습 기법 들이 제시되었지만 가장 주목받는 것은 스파이크 타이밍 의존 가소성(spike-timing-dependent plasticity, STDP)이다. STDP 는 뇌에서 뉴런 사이의 연결이 조정되는 생물학적 특성을 따라, 특정 뉴런에 대한 출력 스파크와 입력 스파이크의 상대적인 시 간 차이를 이용하는 학습 방법이다. STDP의 중요한 특성은 전 후 뉴런 간의 시냅스의 가중치가 대략 수십 밀리세컨드 간격 내에서 상대적인 스파이크 시간에 따라 조정된다는 점이다.[12] 가중치 조절을 수행하는데 사용되는 정보는 시냅스 및 시간에 대해 국소적이다. 보다 자세하게 지도 및 비지도 학습에서의 스 파이킹 신경망의 보편적인 학습 규칙을 살펴볼 필요가 있다.

위에서 언급했듯이 스파이킹 신경망의 비지도 학습은 STDP를 학습 메커니즘의 일부로 포함하는 경우가 대부분이다. 시냅스 전 뉴런이 시냅스 후 뉴런보다 발화(fire)하면, 이들을 연결하는 가중치가 강화된다. 시냅스 전 뉴런이 시냅스 후 뉴런보다 늦게 발화하면 시간적인 스파이크 이벤트 사이의 인과 관계는 가짜이며 시냅스 가중치가 약해진다. 이때 가중치 강화는 장기 강화(long-term potentiation, LTP)이며, 가중치 약화는 장기 억압(long-term depresseion, LTD)이다. '장기'라는 문구는 실험에서 관찰되는 수 밀리미터 단위의 매우 일시적인 효과를 구별하기 위해 사용된다.

다음 공식 (1)은 실험 데이터에 최적화된 한 쌍의 스파이크에서 관찰된 일반적인 STDP 규칙을 나타낸다.[13]

$$\Delta w = \begin{cases} Ae^{\frac{-(t_{pre} - t_{post})}{\tau}} & t_{pre} - t_{post} \le 0, \ A > 0\\ Ae^{\frac{-(t_{pre} - t_{post})}{\tau}} & t_{pre} - t_{post} > 0, \ B < 0 \end{cases}$$
(1)

위 식에서 w는 시냅스의 가중치를 나타낸다. A>0과 B<0는 일반적으로 상수 파라미터로 학습률을 나타내고, τ 는 시간적 학습 윈도우의 시정수를 나타낸다. 위의 수식의 첫 번째는 LTP를, 두 번째는 LTD를 표현한 것이다. 효과의 강도는 감소 지수함수에 의해 조절되며, 크기는 사전 및 사후의 시냅스스파이크 사이의 시정수 스케일된 시간 차이에 의해 제어된다.

생물학적 관점에서, 역전파 훈련 과정이 뇌에서 직접 수행될 수 있는지에 대해 상당한 회의론이 있어왔다. 스파이킹 신경망의 역전파 훈련과 관련하여 모든 종유의 역전파의 변종에서 볼 수 있는 핵심 공식인 수식 (2)에서 볼 수 있는 두 가지중요한 문제가 있다.

$$\delta_k^{\mu} = g'(a_j^{\mu}) \sum_k w_{kj} \delta_k^{\mu} \tag{2}$$

위 식에서 δ_i^μ 와 δ_k^μ 는 임의의 뉴런 j와 k으로의 순 입력에 대 하여 입력 패턴 μ 에 대한 비용함수의 편미분을 나타낸다. 뉴런 j는 뉴런 k들의 집합에 대하여 피드포워드 연결되어 있고 $g(\cdot)$ 은 뉴런 j의 순 입력에 적용되는 활성화 함수이며 순 입 력은 a_i^μ 로 표기된다. w_{ki} 는 단위 j에서 k로 인덱싱된 단위 집합으로 투영되는 피드포워드 가중치이다.[14] 식 (2)의 우변은 역전파의 생물학적으로 가능한 스파이크 버전에 대한 문제점을 나타낸다. 첫째 문제점은 $g'(\cdot)$ 의 계산을 위해 w_{ki} 에 대해 $g(\cdot)$ 이 필요하다. 하지만 $g(\cdot)$ 는 스파이크 뉴런에 적용되므로 디락 델타(Dirac delta) 함수의 합계로 표현될 수 있으며 이는 미분이 존재하지 않는다는 의미이다. 두 번째 문제점은 스파이 킹 및 비 스파이킹 신경망에 적용되는 문제이며 "가중치 이동 (weight transport)"로 불리운다. 가중치 이동은 다음과 같다. $\sum_{i} w_{kj} \delta^{\mu}_{k}$ 는 피드포워드 가중치 w_{kj} 를 피드백 형식으로 사용 한다. 이는 알맞은 대칭적인 피드백 가중치가 반드시 존재해야 하고 식 (2)의 사용을 위하여 정확한 뉴런에 투영되어야 한다.

그동안의 연구에서, 첫 번째 문제는 미분의 대체나 근사를 이용하여 해결되었다.^[10] 하지만 이것은 생물학적으로 가능하지 않다는 것을 인지할 필요가 있다. 예를 들어 시냅스 전 뉴런의 막전위를 대용으로 사용하는 것은 그 값이 시냅스에 대하여

- [11] A. Delorme, J. Gautrais, R. Van Rullen and S. Thorpe, Neurocomputing 26, 989 (1999).
- [12] E. R. Kandel, J. H. Schwartz, T. M. Jessell, S. A. Siegelbaum and A. J. Hudspeth, *Principles of neural science* (McGraw-Hill, New York, 2013).
- [13] N. Caporale and Y. Dan, Annual Review of Neuroscience 31, 25 (2008).
- [14] C. M. Bishop, Neural networks for pattern recognition (Oxford University Press, 1995).

국소적이지 않기에 문제가 된다. 하지만 이러한 접근법은 공학 적 및 과학적 관점에서 여전히 유용하다.

두 번째 문제 해결에 대한 진전은 최근 이루어졌으며 이는 어떠한 임부에서는 무작위 피드백 가중치가 사용되면 역전파가 여전히 잘 수행될 수 있음을 보임에 따른 것이다. 최근 연구에서는 이를 세 가지 종류의 피드백(균일, 무작위, 대칭)을 조사하면서 더욱 확장하였다. [15] 복잡한 문제가 대칭 피드백을 필요로 하는 반면 간단한 문제는 임의의 피드백을 활용하여 해결할 수 있음을 밝혔다. 두 번째 문제해결에 대한 다른 해결방법으로 미러링된 STDP 학습의 도입을 들 수 있다. 이 방안은 계층 사이의 일치된 가중치, 지점 간 연결을 갖춘 STDP 훈련된 자동 부호화기를 활용한다.

스파이킹 신경망의 심층 학습

심층 학습은 학습 가능한 매개 변수의 많은 계층의 구조를 사용하며 기계 학습 및 인공지능 응용 프로그램에서 탁월한 성능을 입증하였다. 심층 신경망은 일반적으로 역전파를 기반으로 하는 최적화 알고리즘을 사용하여 학습된 종단간(end-to-end) 형태이다. [16] 영장류의 뇌에서 다층 신경 구조로 인해 많은 뉴런을 가진 얕은 네트워크 대신에 비선형 신경층의 깊이에 집중할 수 있는 영감을 받았다. 심층 신경망은 역적파 알고리즘을 위한 적절한 플랫폼을 제공하기 위해 비선형, 미분가능한 활성화 함수를 갖춘 순차적 뉴런 계층을 통해 복잡한 특징을 추출한다. 그림 2는 여러 은 닉(hidden) 계층으로 이루어진 심층 신경망 구조를 나타낸다.

대부분의 분류 문제의 경우, 심층 신경망의 출력 계층은 softmax 모듈을 상용한다. 훈련 벡터는 one-hot 부호화를 사용한다. One-hot 부호화에서 각 벡터 구성 요소는 가능한 클래스 중 하나에 해당한다. 이 벡터는 원하는 대상 클래스에 해당하는 1개의 구성 요소가 1로 설정된 이진형태이다. 출력 계층의 softmax 모듈은 각 출력 단위의 값이 0과 1 사이의 값을 가지며 합계는 1이 되도록 설계된다. 이는 상호 배타적이고 포괄적인 확률 값의 집합을 가지게 한다. Softmax 공식은 정규화 지수라고도 불리며 다음과 같이 표현된다.

$$y_i = \frac{\exp(a_i)}{\sum_j \exp(a_j)} \tag{3}$$

위 식에서 a_j 는 특정 출력 단위로의 순 입력을 나타내며 j는 출력 단위의 집합을 지칭하며 y_j 는 출력 단위 i의 값이며 0과 1 사이의 값을 갖는다.

완전 연결(fully connected) 구조 이외에도 심층 합성곱 신경망, 심층 빌리프 신경망, 순환 신경망 등이 있다. 스파이킹

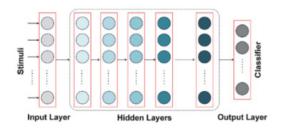


Fig. 2. Simplest deep neural architecture, usually fully connected, with input, hidden, and output layers. The input layer learns to perform pre-processing on the input. The information is then sent to a series of hidden layers, the number of which can vary. As the information propagates through hidden layers, more complex features are extracted and learned. The output layer performs classification and determines the label of the input stimulus, usually by softmax. [2]

신경망 역시 많은 패턴 인식 작업에서 우수한 성능을 보였다. 그러나 직접 훈련된 심층 스파이킹 신경망의 성능은 전통적인 심층 신경망보다 저조하였다. 심층 신경망의 하드웨어 구현에 있어 중요성을 지니고 있기에 기존의 심층 학습에 필적하는 우수한 성능을 갖춘 심층 스파이킹 신경망의 구현은 도전적인 과제이다. 뉴로모픽 플랫폼의 전력 효율과 생물학적 타당성에 힘입어 최근 여러 연구에서 이러한 플랫폼에 대한 심층 스파이킹 신경망 모델들이 개발되었다.

최근 연구들에서 STDP 및 확률적 경사 강하를 활용한 많은 심층 스파이킹 신경망이 개발되었다. 스파이크 기반의 시냅스 가소성 규칙을 갖춘 많은 LIF 뉴런으로 구성된 스파이킹 신경 망은 다양한 패턴 인식 작업에서 우수한 성능을 나타내었다.^[17]

Diehl과 Cook은 2계층 스파이키 신경망을 이용하여 STDP 가 자극으로부터 차별 특징 및 패턴을 추출할 수 있음을 보여 주었다. [18] 비지도 학습을 활용하여 MNIST(Modified National Institute of Standards and Technology) 데이터 셋 인식에서 최고 95%의 정확도를 달성하였다.

시냅스 전후 스파이크 열을 사용하여, O'Connor and Welling는 사전 및 사후 시냅스 스파이크 개수의 외적을 이용하여 심층 스파이킹 신경망에서의 역전파 알고리즘을 개발하였다.^[19] 이를 활용하여 97.93%의 MNIST 데이터 셋 인식 정확도를 달성하여 정류된 선형 유닛(rectified linear units, ReLUs)을 이용한 심층 신경

- [15] T. P. Lillicrap, D. Cownden, D. B. Tweed and C. J. Akerman, Annual Review of Neuroscience 31, 25 (2008).
- [16] J. Schmidhuber, Neural Networks **61**, 85 (2016).
- [17] J. M. Brader, W. Senn and S. Fusi, Neural Computation 19, 2881 (2007).
- [18] P. U. Diehl and M. Cook, Frontiers in Computational Neuroscience 9, 1 (2015).
- [19] P. O'Connor and M. Welling, Deep spiking networks, arXiv preprint arXiv:1602.08323 (2016).

특집 뉴로모픽 컴퓨팅

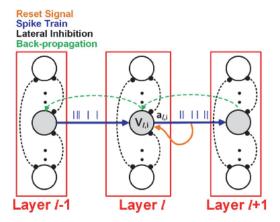


Fig. 3. Deep SNN equipped with backpropagation. The neuron's activation value, al,i, is given by the neuron's membrane potential. The differentiable activation function, which is calculated by the neuron's excitatory input, lateral inhibition, and threshold, is used for developing backpropagation using the chain rule. The output activation value of the current layer (layer I) is used as input for the next layer in the backpropagation algorithm.^[10]

망의 인식 정확도 98,37%와 견줄만한 성공률을 기록하였다. Lee et al.은 뉴런의 막 전위를 전통적인 신경망에서 비선형 활성화함수와 유사한 작용을 하는 미분가능한 신호로 처리한 역전파알고리즘을 제안하였다. [10] (그림 3) 이 심층 스파이킹 신경망의 계산량은 기존 심층 신경망보다 1/5 정도였으나 MNIST 데이터 셋인식 성공률을 98.88%을 달성하였다. Neftci et al.은 이러한 심층 스파이킹 신경망의 학습의 계산량을 더 줄이기 위해 역전파체인 경로를 단순화하는 이벤트 기반 무작위 역 전파(event-driven random backpropagation, eRBP) 알고리즘을 제안하였다. [20] eRBP 규칙은 학습에 뉴런과 시냅스에서 국소적으로 사용 가능한모든 정보에 대하여 오류 변조된 시냅스 가소성을 적용하였다.

보다 전력 효율이 높은 스파이킹 신경망을 활용하기 위한 하드웨어 지향적인 접근 방식은 오프라인으로 훈련된 심층 신경망을 뉴로모픽 스파이크 플랫폼(인공 신경망에서 스파이킹 심층 신경망으로의 변환)이다. 심층 신경망에서 부동 소수점 활성화 값을 대체하기 위해 일반적으로 스파이크 속도 기반 코딩이 사용된다.

심층 합성곱(convolution) 신경망은 대부분 이미지와 관련된 응용에 사용된다. 합성곱과 풀링(pooling) 레이어의 연속적인 조합으로 이루어지며 피드 포워드 분류기가 이어진다. 그림 4는 심층 컴볼루션 신경망의 하나인 LeNet 구조이며 이것은 초기의 심층 합성곱 신경망 중 하나이다. [21] 스파이킹 신경망과 관련하여 전통적인 합성곱 신경망의 특성을 통합하면서 스파이킹 합성곱 신경망의 훈련 기법을 개발하는 것이 중요한 문제이다. 비전(vision)의 경우 첫 번째 합성곱 계층은 주요 시각적 특성을 추출하는 것으로 해석된다. 후속 계층은 분류 목적으로 보다 더복잡한 기능을 추출합한다. 플링 계층은 서브 샘플링(subsam-

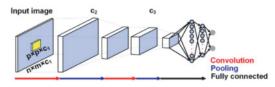


Fig. 4. LeNet architecture. The network consists of two convolutional/pooling layers followed by fully connected layers for image classification.^[21]

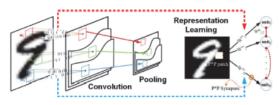


Fig. 5. Representation learning for layer-wise unsupervised learning of a spiking CNN. The excitatory synaptic weights connected to neurons in the representation layer specify convolutional filters. This architecture determines that representation learning in single-layer SNNs can be utilized to train layer-wise spiking CNNs.^[22]

pling)을 수행하고 최대 또는 평균 산술 연산을 사용하여 이전 계층의 크기를 줄인다. 계층 구조의 후반부에서 플링 계층은 방 향, 규모 및 로컬 변환의 변경 사항에 영향을 주지 않는다.

합성곱 신경망은 일반적으로 입력(예: 이미지) 위에 커널 (kernel)을 합성곱하여 자극에서 특징을 추출하기 위해 초기 계층에서 대뇌의 일차 시각 피질과 같은 수용 필드 커널을 사용한다. 피쳐를 추출하기 위해 초기 레이어에서 VI과 같은 수용 필드 커널을 사용한다. 후속 계층은 이전 계층의 커널을 결합하여 보다 복잡하고 추상적인 자극 기능을 학습한다. 표현 필터(훈련되거나 직접 설계한)와 STDP 학습 규칙은 스파이킹 합성곱 신경망의 개발에 적용이 가능하다. 국소 스파이크 기반의 표현 학습 알고리즘에 의해 훈련된 합성곱/풀링 계층은 그림 5에 나타내었다.[25] 직접 제작된(hand-crafted) 합성곱 커널은 높은 분류 성능을 보인 다수의 스파이킹 합성곱 신경망의 첫 번째 계층으로 사용되었으며 Difference-of-Gaussian(DoG)

- [20] E. Neftci, S. Das, B. Pedroni K. Kreutz-Delgado and G. Cauwenberghs, Frontiers in Neuroscience 8, 1 (2014).
- [21] Y. LeCun, L. Bottou, Y. Bengio and P. Haffner, Proceedings of the IEEE **86**, 2278 (1998).
- [22] J. Zylberberg, J. T. Murphy and M. R. DeWeese, PLoS Computational Biology 7, e1002250 (2011).
- [23] S. R. Kheradpisheh, M. Ganjtabesh and T. Masquelier, Neurocomputing **205**, 382 (2016).
- [24] Y. Bengio, P. Simard and P. Frasconi, IEEE Transactions on Neural Networks 5, 157 (1994).
- [25] S. Hochreiter and J. Schmidhuber, Neural Computation 9, 1735 (1997).

는 스파이킹 신경망의 초기 계층에서 특징 추출을 위해 가장 일반적으로 사용되는 직접 제작된 필터이다. 이것은 포유동물 의 일차 시각 피질에 대한 입력을 모방하기 위해 사용되었다.

현재까지의 신경망 중 가장 심층인 STDP 훈련된 합성곱 구조는 입력 계층으로 Difference-of-Gaussian(DoG)를 사용하고 다수의 STDP로 훈련된 합성곱 및 풀링 계층으로 구성된다.^[23]이 신경망 구조는 MNIST 데이터 셋을 이용하여 98.4%의 인식 정확도를 기록하였다.

또한 최근 비 스파이킹 신경망에서 사용되는 역전파 알고리 즉이 Anwani와 Rajendran이 제안한 근사화를 이용하여 스파이킹 신경망의 훈련에도 사용이 되고 있으며 계층적인 스파이킹 합성곱 자동 부호화기를 역전파를 이용하여 구성할 수 있음도 보였다. 심층 스파이킹 합성곱 신경망의 구성을 가능하게하기 위해 스파이킹 합성곱 자동 부호화기는 중요한 모듈이다.

앞에서 기술한 바와 같이, 스파이킹 합성곱 신경망의 훈련을 회피하면서 뉴로모픽 플랫폼을 활용하는 일반적인 접근 방식은 인공 신경망-스파이킹 신경망 변환 방식과 유사하게 이미 훈련 된 가중치를 스파이킹 구조에 매핑하는 규칙을 사용하여 이미 훈련된 합성곱 신경망을 스파이킹 신경망으로 전환하는 것이다.

순환 신경망은 시간 정보를 처리하는 데 사용된다. [24] 순환 신경망을 훈련시키는 가장 일반적인 방법은 시간을 통한 역전 파로, 과거로 들어가는 몇 단계 동안 순환 신경망을 해제한 다음, 전개되지 않은 신경망을 피드포워드 신경망인 것처럼 훈련시킨다. 이렇게 만들어진 피드포워드 신경망에 대해 동일한 순환 가중치가 모든 비 전개 계층을 통해 공유되기 때문에, 특히 경사도 소실 및 폭발의 출현에 따라 매우 긴 시쿼스의 훈련하는데 문제가 있다. 전자의 경우, 네트워크는 학습을 중지하고 후자의 경우 훈련이 불안정해진다.

이러한 문제 때문에 Hochreiter와 Schmidhuber의 연구는 미분의 반복적인 곱셈을 회피하는 CEC(continuous error carousel)라고 불리는 혁신적인 순환 신경망을 개발하였다. [25] 이러한 신경망은 게이트(gated) 순환 신경망으로 알려져 있으며, 기존의 순환 신경망을 사실상 대체했다. 최초의 게이트 순환 신경망은 long short-term memory(LSTM)이다. LSTM과 다른 게이트 순환 신경망은 스파이크 뉴런을 사용하지 않는다는 점에서 전통적인 인공 신경망이지만 반복적 연결이 있는 유닛을 대체한다는 점이 차별화된다. 게이트뿐만 아니라 상태를 포함하는 '셀(cell)'을 가지고 있기 때문에 입력 시퀀스의 구조에 쉽게 적응할 수 있는 장점이 있다. 하지만 순환 스파이킹 신경망은 적은 수가 개발되어 있으며 대부분 기존의 비 스파이킹 순환 신경망을 스파이킹 프레임워크로 변환한 것이다.

 Akopyan et al.은 IBM TrueNorth 뉴로모픽 플랫폼에 에너

 지 효율적인 스파이킹 LSTM을 구현하였다. [26] 이를 위하여 두

가지의 문제를 해결하였는데 첫 번째는 스파이킹 LSTM을 만드는 것이며 두 번째는 뉴로모픽 칩에 구현하는 것이었다. 첫 번째 문제를 해결하기 위해 스파이크 열의 두 개의 채널을 사용하여 양수 및 음수 값을 표현하였다. 이것은 생물학적으로 타당한 DoG 필터이다. 입력, 출력 및 대부분의 내부 LSTM 변수는 스파이크 속도 부호화를 사용하였다.

나가는 말

지도 학습 및 비지도 학습 모델의 심층 스파이킹 신경망의 다계층 학습 기법에서 많은 진전이 이루어졌다. 성능 평가를 위해 심층 스파이킹 신경망의 평가 시 사용되는 벤치마크 데이터 셋의 선택이 가장 중요하다. 최근, 심층 스파이킹 신경망을 이용하여 ImageNet을 학습한 결과에 큰 진전이 이루어졌다. 합성곱 신경망의 평가에 사용되는 정적 프레임 기반의 벤치마크 데이터 셋은 스파이크 및 이벤트 기반 모델을 평가하는데 적합하지 않을 수 있다. 스파이킹 신경망은 높은 정보 값자극의 변화에 응답할 때 가장 잘 수행되므로 희소한 스파이크 비율에 잘 대응되며 지연시간-정확도 균형점을 지원한다.

최근 스파이킹 신경망의 우수한 성능에도 불구하고 생물학적으로 타당한 STDP와 같은 국소 학습 방법을 사용하여 대규모 신경망을 훈련하는 것은 여전히 어려운 과제이다. 한편, 스파이킹 신경망과 인공 신경망 모두에 대하여 지도 훈련 시 역전파 기법은 지점 간 피드백 제한조건으로 인한 난제가 존재하며 해결방법이 부족한 상황이다.

현재까지 주류의 심층 학습 순환 신경망을 스파이킹 신경망으로 변환하려는 시도는 거의 없었다. 스파이킹 신경망은 생물학적 뉴런의 스파이크 특성을 반영하여 개발되었지만 에너지 효율적인 뉴로모픽 컴퓨팅 하드웨어의 출현으로 인하여 과학 및 공학적으로 매우 주목받고 있다. 뉴로모픽 시스템을 위한 알고리즘의 개발을 위하여 뇌과학, 컴퓨터 공학, 뇌공학 등의 여러 학문의 융합이 요구된다. 생물학적 뉴런의 학습 원리의 탐구와 계산 신경과학의 최근 연구결과의 접목이 필요하며 공학적으로 구현하기 위한 알고리즘의 설계가 수반되어야 한다. 최근 신경과학 및 뉴로모픽 공학 분야에서 지속적인 연구결과가 제시되고 있기에 앞으로 향상된 저전력, 고집적 뉴로모픽 하드웨어 및 심층 스파이킹 신경망 기법의 등장을 예상할 수 있다. 스파이킹 신경망과 같이 효율적이지만 생물학적으로 타당한 신경망을 개발하는 것은 인공 지능 및 전산 신경 과학 분야의 기회라고 할 수 있다.

REFERENCES

[26] F. Akopyan *et al.*, IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems **34**, 1537 (2015).

